Сервис поиска электронных книг

Серверная часть, обеспечивающая хранение информации о книгах, поиск по ней и возможность модифицировать её

Иваницкий Андрей

Санкт-Петербургский Академический Университет РАН

1 июня 2010 г.

Руководитель: Н. М. Пульцин

План презентации

Описание проблемы

Проблемы поиска электронных книг

- Проблема единого интерфейса электронных библиотек
- Проблема многих форматов книг

Обзор существующих решений

1. Универсальные поисковые системы (Google, Яндекс)
2. Google books
3. Проект eBdb
4. Amazon Kindle, Sony Reader

5. OPDS
6. BookServer

Описание внутренней структуры системы

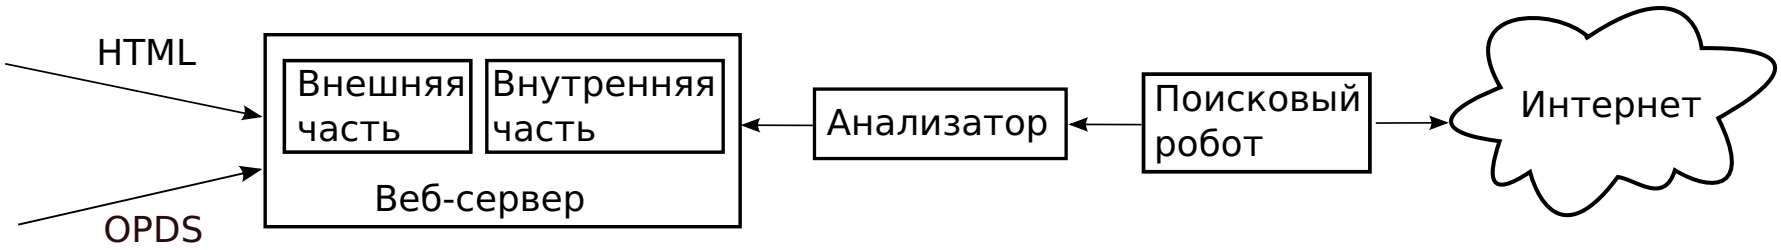

Постановка задачи

1. **Поиск по данным**
   Мощный, быстрый и удобный поиск как для пользователя, так и для анализатора.
2. **Интерфейс модификации данных**
   Полный, гибкий и расширяемый интерфейс модификации данных для анализатора.

Поиск по данным

С помощью Sphinx реализован поисковый механизм

Предоставляет

1. Релевантный поиск как по отдельным сущностям, так и по различным их комбинациям;
2. Фильтрация результатов поиска по некоторым сущностям (язык книги, тэг);
3. Поиск с учётом морфологии языка;
4. Простой поиск (простой в использовании);
5. Исправление опечаток в запросе;
6. Поиск среди авторов по звучанию.

Алгоритм взаимодействия с анализатором

К каждой сущности добавлены два понятия:

1. *индекс доверия (credit)*
2. *индекс релевантности (relevance)*

Если для автора *индекс доверия* и *релевантности* оказались **больше** пороговых значений, то **не создаётся** новой сущности.
В противном случае **создаётся** новый автор.

Если для книги *индекс доверия* и *релевантности* оказались **больше** пороговых значений и авторы этой книги распознались как уже существующие в базе, то новой сущности **не создаётся**.
В противном случае **создаётся** новая книга.

Алгоритм: Расчёт расстояния между строками

Две строки s_1 и s_2 разбиваются на слова:
$s_1 \to S_1 = \{a_1, \ldots, a_n\}$, $s_2 \to S_2 = \{b_2, \ldots, b_m\}$
Пусть $n \leq m$
$M_{i,j} = D_{Levenshtein}(a_i, b_j), i = 1..n, j = 1..m$
где $D_{Levenshtein}$ — расстояние Левенштейна

$$C_{min} = \min_{\alpha_1,\alpha_2,\ldots,\alpha_m} \sum_{i=1}^{n} M_{i,\alpha_i}$$

где $\alpha_1, \alpha_2, \ldots, \alpha_m$ — перестановка чисел от 1 до m,
минимум по всем таким возможным перестановкам
$C_{full} = C_{min} + (m - n) \times C_{remove}$
где C_{remove} — цена добавления/удаления слова.

Структура запроса

Запрос состоит из двух секций: *define*, *update*

```
<?xml version="1.0" encoding="UTF-8"?>
<request>
    <define>
        ...
    </define>

    <update>
        ...
    </update>
</request>
```

Секция define

Определяеются сущности с *уникальным идентификатором ui* (в рамках одного запроса)

```
<author ui="1">
    <full_name> Leo Tolstoy </full_name>
</author>

<file ui="2">
    <link>http://example.com</link>
    <type>pdf</type>
    <size>4563214</size>
</file>
```

Секция update

Обновляются связи между сущностями

```
<book ui="3">
    <authors>
        <author id="343" />
        <author ui="1" />
    </authors>
    <files>
        <file ui="2" />
    </files>
</book>
```

Заключение

1. Разработана внутренняя часть веб-сервера;
2. С помощью Sphinx реализован мощный быстрый поиск;
3. Реализован гибкий, расширяемый протокол взаимодействия с анализатором.

Полная работающая система доступна в Интернете по адресу `http://ebooksearch.webfactional.com/`

Исходный код проекта в репозитории google `http://code.google.com/p/ebooksearchtool/`